

3. 방법 (Method)

3.1 데이터 출처, 표본 구성, 문제 정의

본 연구는 은행 부도 예측(bank failure prediction)을 이진 분류 문제로 정식화한다. 데이터는 Son et al. (2025)[1]의 공개 재현 절차를 따른다. 표본은 NYSE, AMEX, NASDAQ에 상장된 은행을 대상으로 하며, 관측 기간은 1969년 1월부터 2021년 9월까지이다. 모든 재무자료는 COMPUSTAT 데이터베이스에서 수집되었다.

분석 표본은 총 17,881개 은행-연도 관측치로 구성되며, 부도 표본은 약 2.2%로 강한 class imbalance를 가진다. 입력 변수는 금융위기·부도 예측 문헌에서 표준적으로 사용되는 13개 재무비율로 구성된다.

leverage_ratio, asset_liabilities, roe, asset_turnover, debt_ratio, debt_ratio2, roa, capitalization_ratio, longtermdebt_invcap, totaldebt_invcap, cash_debt, debt_ebitda, rect_turn

타깃 변수는 은행의 부도 여부를 나타내는 이진 지표 label이다.

3.2 전처리 및 데이터 분할

모든 입력 변수는 평균 0, 분산 1이 되도록 z-score 정규화를 적용하였다. 데이터 분할은 랜덤 샘플링을 사용하며 train/validation/test 비율을 7:1:2로 고정하였다. 임계값(threshold)은 validation set에서만 선택되며, test set은 최종 성능 평가에만 사용된다. 이로써 feature 선택, threshold tuning, 모델 학습에서 test 정보가 누수되지 않도록 보장한다.

3.3 구조 학습(Structure learning)과 DAG 구성

재무비율 간의 관계를 단순 상관이 아닌 방향성을 갖는 구조로 모델링하기 위해 네 가지 대표적 DAG 학습 알고리즘을 적용하였다.

알고리즘	유형	참고문헌	추정된 edge 수
NOTEARS	Continuous optimization	[2]	17
GOLEM	Likelihood + DAG constraint	[3]	26
PC	Constraint-based	[5]	24
GES	Score-based (BIC)	[4]	35

모든 그래프는 cycle 제거 절차를 통해 DAG로 정규화된다. 이후 이 DAG들은 인과 그래프로 해석되지 않고, feature generator로만 사용된다.

Figure 1-4는 각 알고리즘으로 학습된 재무비율 DAG를 시각화한 것이다.
(Figure captions은 앞서 제공한 텍스트를 그대로 사용)

3.4 DAG 기반 edge feature 생성

각 DAG의 directed edge $u \rightarrow v$ 에 대해 가중치 $w(u \rightarrow v)$ 를 정의한다. NOTEARS와 GOLEM은 알고리즘이 산출한 연속 가중치를 그대로 사용하며, PC와 GES는 구조를 고정한 후 OLS 회귀계수로 edge weight를 추정한다.

각 표본 i 의 edge feature는 다음과 같이 정의된다.

$$f_i(u \rightarrow v) = x_{i,u} \cdot w(u \rightarrow v) \cdot x_{i,v}$$

이는 u 의 수준이 학습된 구조 하에서 v 에 미치는 방향성 기여를 수치화한 것이다. 결과적으로 각 관측치는 원본 13차원 공간과 DAG 기반 상호작용 공간으로 동시에 표현된다.

3.5 Feature set 구성과 edge 선택 규칙

다음 세 가지 feature set을 정의한다.

Set	구성
O	원본 13개 재무비율
F	DAG에서 생성된 edge feature만 사용
OF	원본 13개 + edge feature 결합

F와 OF에서는 edge 수가 알고리즘별로 다르므로(train set 기준) edge feature의 표준편차(std)를 기준으로 내림차순 정렬하여 top-k개를 선택한다. 이 규칙은 label, test set, 구조학습 점수(BIC 등)를 전혀 사용하지 않는 비지도적 선택 규칙이다.

k 는 알고리즘별 최대 edge 수까지 증가한다
(NOTEARS: 17, GOLEM: 26, PC: 24, GES: 35).

3.6 예측 모델과 하이퍼파라미터

다섯 가지 예측기를 사용한다.

모델	주요 hyperparameters
LightGBM	$n_estimators=2000$, $learning_rate=0.02$, $num_leaves=31$, $subsample=0.8$, $colsample_bytree=0.8$
XGBoost	$n_estimators=800$, $max_depth=4$, $learning_rate=0.05$, $subsample=0.8$
Random Forest	$n_estimators=500$, $class_weight=balanced$
Logistic Regression	L2 regularization, $max_iter=2000$
FFMLP	2 hidden layers (128, 64), ReLU, $dropout=0.1$, AdamW

모든 모델은 동일한 데이터 분할과 동일한 feature set 위에서 학습된다. 하이퍼파라미터는

부록에 고정 값으로 보고하며, 본문 비교에서는 representation(O/F/OF)의 효과만 분석한다.

3.7 평가 절차

threshold는 validation set에서 F1을 최대화하는 값으로 결정한다. 평가는 test set에서 수행한다. 성능 지표는 다음을 사용한다.

AUPRC(주 지표), AUROC, F1, Brier score, ECE.

특히 AUPRC는 극단적 불균형 상황에서 positive class(부도) 근방의 순위 품질을 직접 반영하므로 주 지표로 채택한다.

4. 결과 (Results)

4.1 O: 원본 재무비율 기준선

원본 13개 재무비율(O)만으로도 boosting 계열(LightGBM, XGBoost)은 의미 있는 분리 성능을 보인다. 이는 부도 위험이 개별 비율의 수준(level)과 강하게 연관되어 있다는 기존 금융문헌과 일치한다. 그러나 AUPRC는 절대적으로 낮은 수준에 머무르며, 이는 실패 표본 주변에서 순위 품질이 제한적임을 의미한다.

4.2 F: 구조 기반 상호작용의 단독 효과

edge feature만 사용한 F는 원본 수준 정보를 제거했음에도 불구하고 AUPRC와 AUROC 모두에서 무작위 예측을 크게 상회한다. 이는 재무비율 간 방향성 결합이 단일 비율 값으로는 포착되지 않는 부도 신호를 포함함을 의미한다.

그러나 F는 구조학습 오차와 edge weight 추정 오차에 직접 노출되므로, 성능 분산이 O보다 크다. 이는 구조 기반 표현이 “대체재”라기보다는 보완적 신호임을 시사한다.

4.3 OF: 수준 + 구조 결합의 효과

OF는 O와 F를 결합한 표현으로, 대부분의 알고리즘과 모델 조합에서 AUPRC와 F1이 O 대비 개선된다. 이 개선은 단순 차원 증가로 설명되기 어렵다. 이유는 다음과 같다.

1. edge 선택은 label 비의존적이며 train set 통계만 사용한다
2. threshold는 validation에서만 결정되고 test는 완전 독립이다
3. 동일한 분할과 동일한 모델에서 O와 OF를 비교한다

따라서 OF의 개선은 절대 수준 정보와 구조적 상호작용 정보가 서로 보완적으로 작동한 결과로 해석하는 것이 가장 방어 가능하다.

4.4 구조학습 알고리즘 간 비교

GES는 35개의 edge를 생성하여 가장 조밀한 상호작용 표현을 제공하며, NOTEARS는 17개로 가장 희소하다. 조밀한 DAG는 OF에서 더 많은 비선형 결합을 제공하지만, 과도한 edge는 noise를 유발할 수 있다. 따라서 최적 k는 알고리즘별로 상이하게 나타나며, 이는 구조학습 방법이 단순한 사전지식이 아니라 feature space를 재형성하는 하이퍼파라미터임을 의미한다.

4.5 한계

본 연구는 DAG를 인과 그래프로 해석하지 않는다. 관측자료 기반 구조학습은 잠재 교란과 측정오차에 취약하며, 본 연구의 목적은 인과 추론이 아니라 구조화된 상호작용 표현이 예측 성능에 기여하는지를 검증하는 데 있다.

References

- [1] Son, B., Lee, J., Kim, H. Explaining determinants of bank failure prediction via neural additive model. *Applied Economics Letters*, 2025.
- [2] Zheng et al., *NeurIPS* 2018.
- [3] Ng et al., *GOLEM*, 2020.
- [4] Chickering, *JMLR* 2002.
- [5] Spirtes et al., *MIT Press*, 2001.