

II. Data and Method

본 연구는 NYSE, AMEX, NASDAQ에 상장된 은행을 대상으로 하며 COMPUSTAT 재무자료를 사용한다. 데이터 기간은 1969년 1월부터 2021년 9월까지이며, 최종 표본은 17,881개의 은행-연도 관측치로 구성된다. 이 중 약 2.2%가 부도 상태이다. 선행 연구(Meyer and Pifer 1970; Cebula 2010; Shrivastava et al. 2020)를 바탕으로 solvency, profitability, efficiency, capital structure, debt coverage 범주에서 13개의 재무비율을 선택하였다: leverage_ratio, asset_liabilities, roe, asset_turnover, debt_ratio, debt_ratio2, roa, capitalization_ratio, longtermdebt_invcap, totaldebt_invcap, cash_debt, debt_ebitda, rect_turn. 모든 변수는 학습 세트 기준으로 z-score 표준화된다.

은행 부도 예측은 다음과 같은 이진 분류 문제로 정식화된다. 각 은행 n 에 대해 재무비율 벡터 x_n 이 주어질 때, 부도 확률 $P(y_n=1 | x_n)$ 을 추정한다(Meyer and Pifer 1970). 데이터는 무작위로 학습, 검증, 테스트 세트(70-10-20%)로 고정 분할된다. 구조 학습, 간선 가중치 추정, 특징 생성은 모두 학습 세트에서만 수행되며, 분류 임계값은 검증 세트에서 F1 점수를 최대화하도록 선택되고 테스트 세트는 최종 평가에만 사용된다.

기존의 로지스틱 회귀, 결정트리, SVM, 신경망, boosting 모델은 비선형성과 고차원 상호작용을 암묵적으로 포착할 수 있으나, 변수 간의 의존 구조가 어떤 형태의 상호작용으로 모델에 활용되는지는 명시적으로 드러나지 않는다(Kumar et al. 2020; Rudin 2019). 본 연구는 재무비율 간의 방향성을 갖는 통계적 의존 구조를 먼저 추정한 뒤, 이를 표본 수준의 구조 기반 상호작용 특징

(structure-guided interaction features)으로 변환하여 예측기에 제공하는 접근을 채택한다.

이를 위해 NOTEARS(Zheng et al. 2018), GOLEM(Ng et al. 2020), PC(Spirites et al. 2000), GES(Chickering 2002) 알고리즘을 학습 데이터에 적용하여 13개 재무비율 간의 방향성 그래프를 추정한다. 이 그래프는 관측 자료에서 추정된 조건부 의존 관계를 방향성으로 표현한 것으로, 재무비율들 사이의 구조적 연관성을 요약한다. 유한 표본 오차와 수치 최적화로 인해 순환이 발생할 수 있으므로, 각 순환에서 절댓값 가중치가 가장 작은 간선을 반복적으로 제거하여 방향성 비순환 그래프(DAG)를 구성한다.

각 DAG의 간선 $u \rightarrow v$ 에 대해 가중치 $w(u, v)$ 를 정의한다. NOTEARS와 GOLEM에서는 알고리즘이 출력한 가중치를 사용하고, PC와 GES에서는 추정된 구조를 고정된 뒤 학습 데이터에서 선형 회귀 계수로 가중치를 추정한다. 각 표본의 재무비율 벡터를 x 라 할 때, 간선 기반 상호작용 특징은 $f(u, v) = x_u \cdot w(u, v) \cdot x_v$ 로 정의된다. 이는 변수 u 와 v 의 곱에 구조 학습으로부터 얻은 계수를 가중한 값으로, 그래프 구조에 의해 선택된 변수 쌍의 상호작용 강도를 수치화한 것이다.

세 가지 특징 표현을 사용한다. O는 원본 재무비율, F는 DAG에서 선택된 간선들로부터 생성된 상호작용 특징, OF는 두 집합의 결합이다. 예측 모델로는 LightGBM, XGBoost, Random Forest, Logistic Regression, FFMLP를 사용한다. 평가는 AUPRC, AUROC, F1, Brier score, ECE로 수행되며, 확률 출력의 보정을 위해 Platt scaling을 적용한다.

III. Results

Table 2에 따르면, 원본 재무비율(O)만 사용

할 경우 GES-LightGBM의 평균 성능은 AUROC 0.921, AUPRC 0.446이다. 이는 AUROC 기준으로는 양호한 분리 성능을 보이지만, 부도율이 약 2.2%에 불과한 환경에서는 실패 은행을 상위로 식별하는 정밀도(AUPRC)가 제한적임을 보여준다.

DAG에서 선택된 상호작용 특징만을 사용한 F-GES-LightGBM(34 edges)은 AUROC 0.928, AUPRC 0.468을 기록하여 O 대비 AUPRC가 약 2.2%p 증가하였다. 원본 특징과 상호작용을 결합한 OF-GES-LightGBM(47 features)은 AUROC 0.933, AUPRC 0.491, F1 0.479로 가장 높은 성능을 보였으며, 이는 O 대비 AUPRC가 0.446에서 0.491로 약 4.5%p 개선된 것이다.

구조 기반 상호작용 특징의 역할을 확인하기 위해 무작위화 실험을 수행하였다. F-GES-LightGBM에서 Random Weight의 평균 AUPRC는 0.4599로 감소하였고, Random DAG and Weight에서는 0.4214로 더 크게 하락하였다. OF-GES-LightGBM에서도 Random Weight(0.4842)와 Random DAG

and Weight(0.4705)는 원래 구조 기반 OF(0.491)보다 낮은 성능을 보였다. 이는 데이터로부터 학습된 방향성 그래프가 상호작용 특징을 선택하는 데 있어 의미 있는 제약을 제공함을 시사한다.

SHAP 요약 결과에서는 가장 중요한 특징들이 단일 재무비율이 아니라 DAG에서 선택된 상호작용 항임이 나타난다. 특히 edge_GES_asset_turnover_rect_turn, edge_GES_roa_asset_turnover, edge_GES_asset_turnover_totaldebt_invcap, edge_GES_roa_roe, edge_GES_debt_ebitda_roe 등이 높은 평균 SHAP 값을 보인다. 이는 자산 회전을, 수익성(ROA, ROE), 부채 지표들 사이의 구조적으로 선택된 상호작용이 부도 예측에서 중요한 역할을 한다는 것을 보여준다. OF 모델에서도 원본 변수들이 기여하지만, DAG 기반 상호작용 항들이 큰 SHAP 기여를 보여, 구조 기반 특징 표현이 예측기에 실질적인 정보를 제공하고 있음을 나타낸다.