

구조 학습 기반 상호작용 특징을 이용한 은행 부도 예측

이치우

광운대학교 정보융합학부 데이터사이언스

Seoul, Republic of Korea

ichiu305@gmail.com

조민수

광운대학교 정보융합학부

Seoul, Republic of Korea

mcho@kw.ac.kr

Abstract—본 연구는 은행 부도 예측에서 재무비율 간 구조적 의존성을 명시적으로 활용하는 특징 표현을 제안한다. 13개 핵심 재무비율에 대해 NOTEARS, GOLEM, PC, GES를 적용하여 방향성 그래프(DAG)를 추정하고, 그래프의 간선으로부터 구조 기반 상호작용 특징을 생성해 예측기에 입력한다. COMPUSTAT 은행 자료(1969–2021, 17,881 은행-연도, 부도율 약 2.2%)에서 평가한 5회 반복 평균 결과, GES 기반 상호작용 특징과 원본 특징을 결합한 OF-LightGBM이 AUPRC 0.490844, AUROC 0.933477로 가장 우수하였다. 또한 구조 및 가중치를 무작위화하는 검정에서 AUPRC가 감소하여, 학습된 구조가 의미 있는 제약을 제공함을 확인하였다.

Index Terms—Bank failure prediction, causal discovery, DAG, interaction features, NOTEARS, PC algorithm, GES, GOLEM, SHAP

I. METHOD

본 연구는 1969년 1월부터 2021년 9월까지의 COMPUSTAT 은행 재무자료를 사용하며, 총 17,881개의 은행-연도 관측치로 구성된다. 부도 클래스는 약 2.2%로 강한 불균형을 가진다. 예측 문제는 이진 분류로 정식화되며, 은행 n 의 재무비율 벡터 $\mathbf{x}_n$ 이 주어질 때

$$P(y_n = 1 | \mathbf{x}_n) \quad (1)$$

을 추정한다. 원본 재무비율(13개)은 leverage_ratio, asset_liabilities, roe, asset_turnover, debt_ratio,

debt_ratio2, roa, capitalization_ratio, longtermdebt_invcap, totaldebt_invcap, cash_debt, debt_ebitda, rect_turn 이며, 모든 변수는 학습 세트 기준 z-score로 표준화한다. 데이터는 학습/검증/테스트(70/10/20)로 고정 분할하며, 구조 학습 및 특징 생성은 학습 세트에서만 수행한다.

재무비율 간 방향성 구조를 추정하기 위해 NOTEARS, GOLEM, PC, GES를 적용한다. 유한 표본 오차 또는 최적화 오차로 인해 순환(cycle)이 발생할 수 있으므로, cycle을 구성하는 간선 중 절댓값 가중치가 가장 작은 간선을 반복적으로 제거하여 DAG를 얻는다. PC/GES의 경우 가중치 스케일의 일관성 확보를 위해, 알고리즘이 산출한 DAG 구조를 고정된 뒤 학습 데이터에서 선형 회귀 계수로 간선 가중치 $w(i, j)$ 를 추정하여 상호작용 특징 생성에 사용한다.

학습된 DAG의 간선 $i \rightarrow j$ 에 대해 상호작용 특징을

$$f(i, j) = x_i \cdot w(i, j) \cdot x_j \quad (2)$$

로 정의한다. 특징 집합은 $O(\text{원본 } 13\text{개})$, $F(\text{DAG 간선 기반 상호작용})$, $OF(O+F \text{ 결합})$ 으로 구성한다.

예측 모델로 LightGBM, XGBoost, Random Forest, Logistic Regression, FFMLP를 사용한다. 평가 지표는 AUPRC, AUROC, F1, Brier score, ECE이며, 확률 보정을 위해 Platt scaling을 적용한다. 본 논문에서 보고하는

TABLE I
F 설정 AUPRC 기준 Top-10 (5회 평균)

Rank	DAG	Model	K	N_{feat}	AUROC	AUPRC
1	GES	LightGBM	34	34	0.928259	0.470
2	GES	LightGBM	32	32	0.926435	0.460
3	GES	LightGBM	35	35	0.921416	0.460
4	GES	LightGBM	33	33	0.924304	0.460
5	GES	LightGBM	27	27	0.921130	0.440
6	GES	XGBoost	32	32	0.936427	0.440
7	GES	LightGBM	23	23	0.918746	0.440
8	GES	LightGBM	31	31	0.920161	0.430
9	GES	LightGBM	28	28	0.923305	0.430
10	GES	LightGBM	29	29	0.921051	0.430

TABLE II
OF 설정 AUPRC 기준 Top-10 (5회 평균)

Rank	DAG	Model	K	N_{feat}	AUROC	AUPRC
1	GES	LightGBM	34	47	0.934252	0.480
2	GES	LightGBM	33	46	0.930836	0.480
3	NOTEARS	XGBoost	8	21	0.941685	0.480
4	GOLEM	XGBoost	8	21	0.938388	0.480
5	GES	LightGBM	28	41	0.924004	0.480
6	GES	LightGBM	32	45	0.931122	0.480
7	GES	LightGBM	31	44	0.925002	0.480
8	GOLEM	XGBoost	11	24	0.940382	0.480
9	NOTEARS	XGBoost	6	19	0.943393	0.480
10	GES	LightGBM	35	48	0.930376	0.480

메인 성능 표는 서로 다른 seed로 5회 반복한 평균값이다. SHAP은 해석 가능성 제시를 위해 대표 모델(예: seed=42)에서 산출한 결과를 사용한다. 또한 재현성을 위해 구조 학습 하이퍼파라미터는 부록 A에, 최우수 모델에서 사용된 상호작용 특징 목록은 부록 B에 제시한다. 그리드 탐색 결과(Top-10 랭킹)는 본문 Table I, Table II 및 부록 C에 제시한다.

II. RESULTS

본 연구의 평가는 극심한 클래스 불균형(부도율 약 2.2%)을 고려해, 순위 기반 분리 성능(AUROC)뿐만 아니라 실제 부도 은행을 상위로 식별하는 능력을 반영하는 AUPRC를 핵심 지표로 함께 보고한다. 또한 최종 설정 선택의 임의성을 방지하기 위해, DAG 종류/모델/상호작용 개수(K)에 대한 그리드 탐색 결과 중 AUPRC 기준 상위 조합(Top-10)을 함께 제시한다.

A. Model Selection via Top-10 Ranking

Table I은 F 설정(상호작용 특징만)에서 AUPRC 기준 상위 10개 조합이다. 상위권이 GES 기반 구조에 집중되며, 특히 LightGBM에서 $K = 34$ 가 최상위 성능을 기록한다. 이에 따라 F의 대표 설정으로 F-GES-LightGBM($K = 34$)를 선택하였다.

Table II은 OF 설정(원본+상호작용)에서 AUPRC 기준 상위 10개 조합이다. OF에서도 $K = 34$ 의 GES-

TABLE III
GES-LIGHTGBM 성능 비교(5회 평균)

특징 집합	AUPRC	AUROC	F1
O (13)	0.445720	0.921241	0.465540
F (34)	0.467982	0.927717	0.452782
OF (47)	0.490844	0.933477	0.478985

LightGBM이 최상위 성능을 기록하며, 이 설정이 본 연구의 최종 모델(OF-GES-LightGBM, $K = 34$, 총 47 features)로 채택되었다.

B. Main Comparison: O vs F vs OF

Table III은 선택된 설정을 기준으로 O/F/OF의 5회 반복 평균 성능을 비교한다. O만 사용하면 AUPRC 0.445720이며, F(상호작용만)는 AUPRC 0.467982로 상승한다. 이는 구조 학습이 선택한 변수쌍의 상호작용이 불균형 환경에서 양성(부도) 식별에 추가 정보를 제공함을 시사한다. OF는 AUPRC 0.490844로 가장 높다. 해석적으로, OF의 개선은 원본의 기본 위험 신호 위에 구조가 선택한 결합 패턴을 추가하여 부도 후보를 상위로 재정렬(reranking)하는 효과로 이해할 수 있다.

TABLE IV
구조 무작위화 검증(5회 평균, GES-LIGHTGBM)

SET	조건	AUPRC	AUROC	F1
F	Original	0.467982	0.927717	0.452782
F	Random Weight	0.459854	0.929356	0.447985
F	Random DAG+Weight	0.421388	0.909476	0.417487
OF	Original	0.490844	0.933477	0.478985
OF	Random Weight	0.484200	0.933948	0.488587
OF	Random DAG+Weight	0.470495	0.933581	0.470679

C. Randomization Test (Random Weight / Random DAG+Weight)

구조 기반 상호작용의 기여가 단순히 상호작용 항을 추가했기 때문인지(차원 증가 효과) 검증하기 위해, (i) 구조는 유지하되 가중치만 무작위(Random Weight), (ii) 구조와 가중치를 모두 무작위(Random DAG+Weight)로 바꾼 비교를 수행하였다(Table IV). F에서 Random Weight는 AUPRC가 0.459854로 감소하며, Random DAG+Weight는 0.421388로 더 크게 하락한다. OF에서도 원본 OF(0.490844) 대비 Random Weight(0.484200), Random DAG+Weight(0.470495)로 AUPRC가 감소한다. 즉, OF의 개선은 단순한 차원 증가가 아니라, 학습된 구조가 제공하는 유효한 제약에 의해 설명된다.

마지막으로, 최고 성능 모델의 예측 근거를 확인하기 위해 SHAP 분석을 수행하였다. Figure 2와 Figure 3에서, F는 상호작용 항이 중요도를 대부분 차지하는 반면, OF는 원본 변수와 상호작용 항이 함께 상위에 위치한다. 이는 OF가 원본 특징의 기본 위험 신호를 보강하면서, 특정 조합에서의 조건부 효과를 포착함을 시사한다.



Fig. 1. 구조 학습 알고리즘별 재무비율 DAG. 상단 왼쪽: GES, 상단 오른쪽: GOLEM, 하단 왼쪽: NOTEARS, 하단 오른쪽: PC.




Fig. 2. F-GES-LightGBM SHAP summary(대표 모델, 예: seed=42).




Fig. 3. OF-GES-LightGBM SHAP summary(대표 모델, 예: seed=42).

APPENDIX A
STRUCTURE LEARNING HYPERPARAMETERS

- A. *NOTEARS*
- B. *PC Algorithm*
- C. *GES*
- D. *GOLEM*

TABLE V
NOTEARS HYPERPARAMETERS

Parameter	Value
RANDOM_STATE	42
MAX_FEATURES	None
LOSS_TYPE	"l2"
W_THRESHOLD	0.0
ENFORCE_DAG_SAFETY	True
λ_1	0.1 (9 edges) 0.01 (13 edges) 0.005 (17 edges, main) 0.0005 (20 edges)

TABLE VI
PC HYPERPARAMETERS

Parameter	Value
ALPHA	0.01
USE_STANDARDIZE_FOR_OLS	True
OLS_RCOND	None
EPS_EDGE	1×10^{-12}
stable	True
uc_rule	0
uc_priority	2

TABLE VII
GES HYPERPARAMETERS

Parameter	Value
RANDOM_STATE	42
MAX_FEATURES	None
GES_SCORE_FUNC	"local_score_BIC"
CYCLE_BREAK_STRATEGY	"min_abs_score"
USE_STANDARDIZE_FOR_OLS	True
OLS_RCOND	None
EPS_EDGE	1×10^{-12}

TABLE VIII
GOLEM HYPERPARAMETERS

Parameter	Value
MODE	"nv"
INIT_EV	True
LAMBDA1	0.02
LAMBDA2	5.0
OMEGA	0.3 (11 edges) 0.2 (17 edges) 0.1 (26 edges, main)
MAX_STEPS	4000
LR	1×10^{-3}
PRINT_EVERY	400
INIT_EV_STEPS	1500
RANDOM_STATE	42
MAX_FEATURES	None
Internal numerical ϵ	$\approx 1 \times 10^{-12}$

APPENDIX B

SELECTED DAG-BASED INTERACTION FEATURES

A. $F - GES - LightGBM$ (34 edges)

edge_GES__asset_liabilities__rect_turn
 edge_GES__asset_liabilities__debt_ratio
 edge_GES__debt_ratio__rect_turn
 edge_GES__debt_ratio__leverage_ratio
 edge_GES__roa__asset_turnover
 edge_GES__asset_turnover__rect_turn
 edge_GES__roa__roe
 edge_GES__asset_liabilities__leverage_ratio
 edge_GES__debt_ratio2__capitalization_ratio
 edge_GES__debt_ratio__roa

edge_GES__roa__rect_turn
 edge_GES__debt_ratio2__longtermdebt_invcap
 edge_GES__debt_ratio2__totaldebt_invcap
 edge_GES__debt_ebitda__debt_ratio2
 edge_GES__debt_ratio2__roa
 edge_GES__cash_debt__asset_liabilities
 edge_GES__roa__totaldebt_invcap
 edge_GES__asset_turnover__totaldebt_invcap
 edge_GES__asset_turnover__leverage_ratio
 edge_GES__roa__leverage_ratio
 edge_GES__cash_debt__debt_ratio2
 edge_GES__debt_ebitda__roa
 edge_GES__asset_turnover__roe
 edge_GES__debt_ratio2__leverage_ratio
 edge_GES__debt_ratio__capitalization_ratio
 edge_GES__asset_turnover__capitalization_ratio
 edge_GES__debt_ebitda__roe
 edge_GES__cash_debt__totaldebt_invcap
 edge_GES__debt_ratio2__debt_ratio
 edge_GES__asset_liabilities__roe
 edge_GES__debt_ratio__roe
 edge_GES__cash_debt__rect_turn
 edge_GES__cash_debt__debt_ratio
 edge_GES__cash_debt__longtermdebt_invcap

B. $OF - GES - LightGBM$ (47 features)

leverage_ratio
 asset_liabilities
 roe
 asset_turnover
 debt_ratio
 debt_ratio2
 roa
 capitalization_ratio
 longtermdebt_invcap
 totaldebt_invcap
 cash_debt
 debt_ebitda
 rect_turn
 edge_GES__asset_liabilities__rect_turn
 edge_GES__asset_liabilities__debt_ratio
 edge_GES__debt_ratio__rect_turn
 edge_GES__debt_ratio__leverage_ratio
 edge_GES__roa__asset_turnover
 edge_GES__asset_turnover__rect_turn
 edge_GES__roa__roe
 edge_GES__asset_liabilities__leverage_ratio
 edge_GES__debt_ratio2__capitalization_ratio

edge_GES__debt_ratio__roa
 edge_GES__roa__rect_turn
 edge_GES__debt_ratio2__longtermdebt_invcap
 edge_GES__debt_ratio2__totaldebt_invcap
 edge_GES__debt_ebitda__debt_ratio2
 edge_GES__debt_ratio2__roa
 edge_GES__cash_debt__asset_liabilities
 edge_GES__roa__totaldebt_invcap
 edge_GES__asset_turnover__totaldebt_invcap
 edge_GES__asset_turnover__leverage_ratio
 edge_GES__roa__leverage_ratio
 edge_GES__cash_debt__debt_ratio2
 edge_GES__debt_ebitda__roa
 edge_GES__asset_turnover__roe
 edge_GES__debt_ratio2__leverage_ratio
 edge_GES__debt_ratio__capitalization_ratio
 edge_GES__asset_turnover__capitalization_ratio
 edge_GES__debt_ebitda__roe
 edge_GES__cash_debt__totaldebt_invcap
 edge_GES__debt_ratio2__debt_ratio
 edge_GES__asset_liabilities__roe
 edge_GES__debt_ratio__roe
 edge_GES__cash_debt__rect_turn
 edge_GES__cash_debt__debt_ratio
 edge_GES__cash_debt__longtermdebt_invcap

APPENDIX C

ADDITIONAL TOP-10 RANKINGS

A. *F* 설정 AUROC 기준 Top-10 (5회 평균)

B. *OF* 설정 AUROC 기준 Top-10 (5회 평균)

C. *F1* 기준 Top-10 (5회 평균)

TABLE IX
F 설정 AUROC 기준 Top-10

Rank	DAG	Model	K	N_{feat}	AUROC	AUPRC
1	GES	XGBoost	25	25	0.937092	0.40
2	GES	XGBoost	32	32	0.936427	0.44
3	GES	XGBoost	22	22	0.935837	0.40
4	GES	XGBoost	17	17	0.935703	0.34
5	GES	XGBoost	33	33	0.935070	0.43
6	GES	XGBoost	18	18	0.934711	0.36
7	GES	XGBoost	28	28	0.934563	0.418
8	GES	XGBoost	24	24	0.934172	0.417
9	GES	XGBoost	21	21	0.933868	0.38
10	GES	XGBoost	20	20	0.933441	0.38

TABLE X
OF 설정 AUROC 기준 Top-10

Rank	DAG	Model	K	N_{feat}	AUROC	AUPRC
1	GES	XGBoost	18	31	0.946327	0.46
2	PC	XGBoost	8	21	0.945868	0.48
3	GES	XGBoost	19	32	0.945452	0.45
4	GES	XGBoost	33	46	0.943754	0.47
5	NOTEARS	XGBoost	4	17	0.943678	0.48
6	NOTEARS	XGBoost	5	18	0.943668	0.47
7	NOTEARS	XGBoost	10	23	0.943436	0.46
8	NOTEARS	XGBoost	6	19	0.943393	0.48
9	GES	XGBoost	8	21	0.943371	0.47
10	NOTEARS	XGBoost	7	20	0.943052	0.47

TABLE XI

F1 기준 TOP-10 (동일 표에서 AUROC/AUPRC를 함께 보고)

Rank	DAG	Model	K	N_{feat}	AUROC	AUPRC
1	PC	LightGBM	22	35	0.912189	0.46
2	GES	LightGBM	17	30	0.934863	0.46
3	PC	LightGBM	20	33	0.914895	0.46
4	GES	LightGBM	22	35	0.926891	0.46
5	GES	LightGBM	24	37	0.928437	0.46
6	GES	XGBoost	28	41	0.939756	0.47
7	GES	LightGBM	19	32	0.931784	0.47
8	GES	XGBoost	17	30	0.942908	0.46
9	PC	XGBoost	22	35	0.931802	0.44
10	PC	LightGBM	23	36	0.918977	0.47

REFERENCES

- [1] X. Zheng, B. Aragam, P. Ravikumar, and E. P. Xing, “DAGs with NO TEARS: Continuous optimization for structure learning,” in *NeurIPS*, 2018.
- [2] I. Ng, A. Ghassami, and K. Zhang, “On the role of sparsity and DAG constraints in causal discovery,” in *ICML*, 2020.
- [3] M. Kalisch and P. Bühlmann, “Estimating high-dimensional directed acyclic graphs with the PC-algorithm,” *JMLR*, 2007.
- [4] D. M. Chickering, “Optimal structure identification with greedy search,” *JMLR*, 2002.
- [5] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in *NeurIPS*, 2017.
- [6] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *NeurIPS*, 2017.